


Redes Neurais Aplicadas a Negócios

MBA em Inteligência Artificial e Analytics Aplicadas a Negócios — FGV

Bloco A — Alinhamento Conceitual

Inteligência → IA → Evolução → Tipos → Neurônios → Redes Neurais



Abertura, apresentações e Expectativas



Marco Fidos

Head de IA & Innovation, Keyrus

+ 20 anos liderando tecnologia, dados e inovação na América Latina, ele é responsável pela agenda de IA da Keyrus e pelo desenvolvimento de soluções para clientes, unindo uma rara combinação de engenharia, negócio e visão comercial para transformar inteligência artificial em valor real.

- ✓ Membro do CoE AI – Global Keyrus
- ✓ Professor – PUCS, FGV...

EXPERIÊNCIA

- ✓ Keyrus – Head de IA e Inovação
- ✓ Atech (Embraer): Gerente Técnico – Soluções de IA, Big Data e Analytics
- ✓ Inovação GIS: +11 anos na direção executiva
- ✓ DigitalGlobe / Maxar: Country Manager LatAm
- ✓ Oficial do Exército

JORNADA

- ✓ Doutorado em Eng. Eletrônica e Computação ITA – Arquitetura de Sistemas de Raciocínio Neuro-Simbólico
- ✓ Mestre em Engenharia de Sistemas Espaciais – INPE
- ✓ MBA Gestão Empresarial – FGV
- ✓ Palestrante: ITA, ECEME, COTER, AI Summit BR, AI Data Leaders...
- ✓ Pesquisador CNPq, ANATEL - Autor de artigos científicos (IEEE - Explainable AI, Machine Learning) e Arquiteturas de Sistemas de Informação

A — Alinhamento Conceitual (aula de hoje)

Inteligência, IA, tipos de IA, neurônios artificiais, redes neurais

- B — Projetos de IA e Desafios Empresariais

Exemplos reais de projetos de IA e quando (não) usar IA

- C — Design de Projetos de IA

Coleta e preparação de dados, calibragem e avaliação

- D — Uso de IA Generativa como copiloto

Antigravity, Git/GitHub e Gamma no fluxo de trabalho

- E — Apresentação dos trabalhos finais

Miniprojeto de ML com redes neurais

ROTEIRO

BLOCO A

Nesta aula, construiremos uma compreensão sólida sobre o tema, navegando pelos seguintes tópicos:

Inteligência

Inteligência Artificial (IA)

Evolução da IA

Tipos de IA

Neurônios Artificiais

Redes Neurais

Bem-vindos

Marco Fidos

Head of IA and Innovation


- ✓ Quem está na sala?
- ✓ Qual sua experiência prévia com IA e redes neurais?



1. O que é inteligência, no contexto do ser humano?

Inteligência é um constructo multidimensional; portanto, “definição de Inteligência, humana ou artificial” não é uma pergunta binária simples.

Inteligência Humana - Escalas de Inteligência




1. Inteligências Múltiplas (Gardner) - 1983

A inteligência se estende além das medições tradicionais de QI.

- Linguística & Lógico-Matemática
- Visual-Espacial & Musical
- Corporal-Cinestésica & Interpessoal
- Intrapessoal & Naturalista

Gardner, H. (1983). [Frames of Mind: The Theory of Multiple Intelligences](#). Basic Books;

Gardner, H. (2006). [Multiple Intelligences: New Horizons](#). Basic Books.



2. Inteligência Emocional (Goleman) - 1995

Concentra-se na consciência emocional e gestão de relacionamentos.

- Autoconsciência & Autorregulação
- Motivação & Empatia
- Habilidades sociais

Goleman, D. (1995). [Inteligência Emocional](#). Objetiva; Goleman, D. (1998).

[Trabalhando com a Inteligência Emocional](#). Objetiva;

Mayer, J. D., & Salovey, P. (1997). [What is emotional intelligence?](#) Em P. Salovey & D.

Sluyter (Eds.), Emotional development and emotional intelligence




3. Winograd Schema Challenge - 2012

Testes de desambiguação que exigem compreensão contextual e conhecimento de mundo para resolver corretamente.

Referência: Levesque, H. J., Davis, E., & Morgenstern, L. (2012). The Winograd schema challenge. KR, 12, 552-561.

Inteligência Humana - Escalas de Inteligência



4. Escalas de Inteligência de IA - 2014

- Escala de 4 níveis da DARPA (Reativa a Raciocínio)

DARPA (2018). [AI Next Campaign](#); Bostrom, N. (2014).



5. Testes de Capacidades Cognitivas - 2019

Avaliações que medem habilidades específicas como raciocínio lógico, compreensão de linguagem natural e resolução de problemas em domínios diversos.

Referência: Chollet, F. (2019). On the measure of intelligence. arXiv preprint arXiv:1911.01547.



6. Avaliações de Viés e Equidade - 2018

Análises que mensuram a presença de preconceitos sociais e limitações éticas nos sistemas de IA.

Referência: Buolamwini, J., & Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. Conference on fairness, accountability and transparency, 77-91.

2. E a Inteligência Artificial?

IA – É de comer ou de passar no cabelo?

Alinhando expectativas

*Diferentes
Perspectivas...*

*Diferentes
Impacto...*




O que é IA?

Sistemas de computador que **aumentam a inteligência humana** através de tarefas como classificação, aprendizado, abstração, perceber, raciocinar e/ou agir.

Escalas de Inteligência

Uma progressão de capacidade, não uma escala binária.



As Três Ondas da IA

Framework da DARPA para classificar a evolução das capacidades de IA.

	01	02	03
	Conhecimento Codificado	Aprendizado Estatístico	Adaptação Contextual
	Handcrafted Knowledge	Statistical Learning	Contextual Adaptation
COMO FUNCIONA	Regras e lógica definidas por humanos; símbolos manipulados por regras formais do tipo “se-então”.	Reconhecimento de padrões orientado por dados — machine learning sobre grandes volumes.	Modelos explicativos do mundo real, combinando raciocínio simbólico e aprendizado estatístico.
PONTOS FORTES	Domínios bem estruturados; pouco dado necessário; decisões explicáveis.	Lida com dados não estruturados; escala com mais dados e computação.	Compreensão contextual entre domínios; transferência; multimodalidade.
LIMITAÇÕES	Frágil diante do imprevisto; gargalo na aquisição de conhecimento.	Pouco interpretável (“caixa-preta”); custo alto; raciocínio causal fraco.	Fronteira de pesquisa; riscos de confiabilidade e custo elevado.
EXEMPLO	MYCIN, diagnóstico por regras (1970).	AlexNet no ImageNet (2012).	Objetivo de pesquisa (Launchbury, 2017).*

Launchbury, J. (2017). A DARPA Perspective on Artificial Intelligence. · * Leituras posteriores associam a Onda 3 a modelos de fundação (GPT-4, Claude, Gemini).

Testando a inteligência de uma máquina

Teste de Turing (1950)

Um avaliador humano conversa, às cegas, com um humano e uma máquina — se não conseguir distinguir quem é quem, a máquina "passou" no teste.



Sala Chinesa de Searle (1980)

Uma crítica ao Teste de Turing — alguém dentro de uma sala manipula símbolos chineses seguindo regras, produzindo respostas corretas sem entender chinês. Levanta a pergunta: processar símbolos corretamente é o mesmo que compreender?



Processar símbolos corretamente é o mesmo que compreender?

**Turing pergunta operacionalmente:
“O comportamento é indistinguível de um
comportamento inteligente?”**

**Searle responde com outra pergunta:
“Comportamento aparentemente inteligente
implica compreensão?”**

Tópico Extra

**Reflexão: Inteligência Humana x
Inteligência Artificial, como anda
esta corrida?**

ESCALAS DE COMPUTAÇÃO

Cérebro Humano

NEURÔNIOS E SINAPSES

86 bilhões de neurônios

~1 quadrilhão (10^{15}) de sinapses

EFICIÊNCIA ENERGÉTICA

~20 W

PROCESSAMENTO

Massivamente paralelo

~1.000 a 10.000 operações por segundo por sinapse

ARMAZENAMENTO ESTIMADO

1–2 petabytes

1.000 a 2.000 terabytes

A capacidade de processamento total é difícil de medir em termos absolutos, dada a natureza dos processos cognitivos e a integração de múltiplas formas de informação — por isso não convertemos isso em FLOPS.

Supercomputador Clássico (atual)

Sistema mais rápido do mundo hoje — Top500, jun/2026.

01	LineShine China	2,198 exaFLOPs
02	El Capitan EUA	1,809 exaFLOPs
03	Frontier EUA	1,353 exaFLOPs

NÚCLEOS

Dezenas de milhões — o LineShine usa 13,8 milhões de núcleos.

CAPACIDADE DE RAM

Da ordem de exabytes, distribuída entre nós, cada um com dezenas de terabytes.

Para efeito de comparação didática: mesmo o sistema mais rápido do mundo hoje ainda está na casa de poucos exaFLOPs — ordens de grandeza abaixo da meta teórica de 10 exaFLOPs (10^{19} operações/segundo) usada como referência de “supercomputador de próxima geração”.

Computador Quântico: onde estamos

COMPUTADOR	QUBITS	DESTAQUE
Google Sycamore	53 operacionais	Supremacia quântica anunciada em 2019
IBM Condor	1.121	Lançado em dez/2023 — não é mais “planejado”
D-Wave Advantage	5.000	Foco em otimização e amostragem quântica
Rigetti Aspen-9	32	Plataforma Forest para algoritmos quânticos
IonQ Aria	25 íons presos	Alta fidelidade, precisão e estabilidade

Sistemas atuais: alta fidelidade e tempo de coerência ainda limitado · processamento paralelo com múltiplos qubits interconectados · refrigeração criogênica próxima do zero absoluto · algoritmos quânticos especializados.

Ainda experimentais e sujeitos a erro/decoerência — mas com potencial de vantagem em problemas específicos (otimização, simulação molecular).

Cifras de qubits do material original — D-Wave, Rigetti e IonQ não revalidados nesta revisão. IBM Condor confirmado (1.121 qubits, dez/2023).

Cérebro, Supercomputador e Computador Quântico — mesma régua, três leituras

	Cérebro Humano <i>a referência biológica</i>	Supercomputador Clássico <i>LineShine — Top500, jun/2026</i>	Computador Quântico <i>sistema supercondutor típico</i>
Energia (potência)	~20 W consumo basal (repouso) <i>medido — valor padrão em neurociência</i>	42.220 kW para entregar 2,198 exaFLOPS <i>medido — TOP500, jun/2026</i>	~26 kW refrigeração + eletrônica de controle <i>medido — ex.: Google Sycamore</i>
Processamento (FLOPS)	10¹⁵–10¹⁸ FLOPS faixa de estimativas <i>estimado — 4 ordens de grandeza de incerteza (Drexler, 2018; Sandberg & Bostrom, 2008)</i>	2,198 exaFLOPS = 2,198 × 10 ¹⁸ FLOPS <i>medido — benchmark Rmax (Linpack)</i>	Não se aplica arquitetura não opera em FLOPS <i>qubits não são uma unidade de processamento comparável</i>
Armazenamento (capacidade)	~1 PB capacidade sináptica estimada <i>Bartol et al., 2016, eLife (Salk Institute)</i>	~5,7 PB memória RAM — El Capitan (HBM3) <i>44.544 GPUs MI300A × 128GB cada</i>	Não retém dados coerência de microssegundos a milissegundos <i>teorema da não-clonagem — limite físico, não tecnológico</i>

Energia: o cérebro consome ~2 milhões de vezes menos que o supercomputador líder para operar.


Processamento: só o supercomputador tem um valor medido; o cérebro é estimativa, e o quântico não converte em FLOPS.

Armazenamento: cérebro e supercomputador guardam informação; o computador quântico, por física, não pode.


Fontes: TOP500, junho de 2026 (top500.org/lists/top500/2026/06). El Capitan: Wikipedia (en.wikipedia.org/wiki/El_Capitan_(supercomputer)). Estimativas de FLOPS do cérebro: Drexler (2018); Sandberg & Bostrom, "Whole Brain Emulation: A Roadmap" (2008), via AI Impacts (aiimpacts.org/brain-performance-in-flops). Armazenamento sináptico: Bartol et al., "Nanocconnectomic Upper Bound on the Variability of Synaptic Plasticity", eLife, 2016 (Salk Institute). Consumo de sistemas quânticos: PatentPC, "Quantum Computing Energy Consumption" (2026).

3. Evolução da Inteligência Artificial

Timeline da IA




S. McCulloch – W. Pitts



- Adjustable Weights
- Weights are not Learned



F. Rosenblatt




- Learnable Weights and Threshold



B. Widrow – M. Hoff




M. Minsky – S. Papert



- XOR Problem




D. Rumelhart – G. Hinton – R. Williams



- Solution to nonlinearly separable problems
- Big computation, local optima and overfitting




V. Vapnik – C. Cortes



- Limitations of learning prior knowledge
- Kernel function: Human Intervention



G. Hinton – S. Ruslan



- Hierarchical feature Learning

Inteligência Artificial

Fundamentos matemáticos
(neurônio artificial é formulado) →
Financiamento público.

● — 1943-56

1956-73

— ●

Em 20 anos, máquinas farão qualquer trabalho humano" (Simon, 1965). O relatório Lighthill (1973) provou o contrário — e o financiamento público foi cortado.

Sistemas especialistas prometiam substituir consultorias. Quebrou.

Neurônio Artificial dá seu primeiro salto (aprende sozinho, via backpropagation, 1986).
Em **2012** convence o mercado (AlexNet).

● — 1973-2012

2014-2017

— ●

Nasce a atenção (2014), ainda presa a redes neurais tradicionais.
2017 - Transformer, a arquitetura por trás de todo LLM atual.

75 anos. Da ideia até a eficácia e viabilidade.

Inteligência Artificial

Como o neurônio artificial evoluiu — em 5 saltos

1943-1986 — "O sensor que aprende com o erro": imagine um sistema simples verificando se um número num relatório está dentro do limite ou fora. No início, ele erra e não aprende nada com isso. A partir de 1986, ele passa a ajustar sozinho toda vez que erra.

1943-1986



2012



2012 — "A linha de inspeção": em vez de um sensor olhando um número isolado, várias leituras especializadas do relatório trabalham juntas — uma olha vendas, outra custo, outra prazo — e juntas percebem um problema que nenhuma sozinha veria.

2012



2014-2017



2014-2017 — "A memória sem fila": o sistema passa a lembrar o que já leu no relatório (2014) e, em 2017, para de precisar ler linha por linha em sequência — consegue olhar o relatório inteiro de uma vez. É por isso que hoje você cola um relatório de 50 páginas num chat e recebe resposta em segundos.

IA Generativa – 2017-2025

Bilhões em capital privado migram para poucos laboratórios (OpenAI, DeepMind, Anthropic) — o produto ainda é experimento de pesquisa, não ferramenta de mercado.

ChatGPT chega ao público nov/22 — 100M users em jan/23. Empresas experimentam em 2023.

A EXPECTATIVA: "Isso vai mudar tudo"

Technology push
Hammer looking
for a nail



2017-22

A APOSTA
"Quem chegar primeiro, domina a próxima década"

2022 / 23

Adoção em massa começa — modelos evoluem rápido e investimento em infraestrutura dispara nos bastidores. US\$ 226bi em capex em infraestrutura. GPT-4o/Claude 3.5/Gemini 1.5

2024

2025


Copilotos e assistentes pessoais se multiplicam — PoCs em todo canto, pressão comercial pesada dos hyperscalers, mas poucos provam ROI.
A ILUSÃO: Temos 1000 usuários, Criamos 40 agentes mas não me pergunte de ROI.

IA Generativa – 2026

A METR mede o tempo de tarefa real (não pergunta teórica) que um humano qualificado leva pra terminar, e testa se a IA aguenta o mesmo tempo sozinha, sem supervisão, com 50% de sucesso.

- ✓ Essa métrica dobra a cada 4 meses, desde 2024.
- ✓ Em 2019, a IA aguentava tarefas de 2 segundos; e em 2026, quase 16 horas.


A. Evolução tecnológica — potencial vs. humano



De segundos (achar um fato, contar palavras) a horas (treinar um modelo, otimizar código) — a régua é tempo de trabalho autônomo, não conhecimento.

The Stanford AI Index Report

A. Evolução tecnológica — potencial vs. humano



IA Generativa – 2026




<https://video-zero-shot.github.io>

Google DeepMind (Veo 3)

A. Evolução tecnológica — potencial vs. humano




<https://www.youtube.com/shorts/S7qQYlqZS2Y?feature=share>



- ✓ **ICPC World Finals 2025** (Maratona de Programação, a competição de programação mais disputada do mundo, com os melhores universitários do planeta) - o modelo da OpenAI cravou 12 de 12 problemas — nota perfeita, superando todas as equipes humanas participantes.
- ✓ **Olimpíada Internacional de Matemática (IMO) 2025**, tanto Gemini quanto o modelo da OpenAI atingiram nota de medalha de ouro — mas humanos ainda tiraram as notas mais altas (5 pontuações perfeitas).


**Agentes de IA
capazes de executar
fluxos completos de
trabalho!**

IA Generativa – 2026




<https://www.statista.com/chart/35046/capital-expenditure-of-meta-alphabet-amazon-and-microsoft/>

B. Infraestrutura + usuários + receitas



<https://api.backlinko.com/app/uploads/2024/06/chatgpt-weekly-active-users-worldwide.png>

- ✓ Passou de 1 bilhão de usuários mensais em jun/2026



<https://sqmagazine.co.uk/chatgpt-claude-gemini-perplexity-statistics/>


Tendências da IA: O que esperar

Sinais e Possíveis desdobramentos da IA

Sinais — Horizon

Scanning (varredura de sinais fracos)

- IFTF
- Copenhagen Institute for Futures Studies



- ✓ Meu futuro, seu futuro
- ✓ Futuro se constrói....

Tendências da IA: O que esperar

Sinais e Possíveis desdobramentos da IA

Sinais — Horizon

Scanning (varredura de sinais fracos)

- IFTF
- Copenhagen Institute for Futures Studies

Do [Gartner Hype Cycle 2026:](#)

- ✓ IA agêntica está no "pico de expectativas infladas" — só 17% das empresas já implementaram agentes de IA, mas mais de 60% planejam fazer isso nos próximos 2 anos.
- ✓ Esse gap ambição-realidade é ele mesmo um sinal forte (**todo mundo vai tentar, poucos vão acertar de primeira**).
- ✓ Governança de agentes, segurança de agentes e "FinOps para IA" estão virando prioridade — sinal de que a fase de "só usar" está acabando e **a fase de "controlar o que já está rodando"** está começando.

Do [WEF Future of Jobs 2025:](#)


- ✓ 86% das empresas esperam que IA transforme o negócio até 2030.
- ✓ Estimativa de 92 milhões de empregos deslocados e 170 milhões criados (saldo líquido positivo de +78 milhões) até 2030.
- ✓ 39% da força de trabalho vai precisar se requalificar nesse período.

Tendências da IA: O que esperar

Sinais e Possíveis desdobramentos da IA

Desdobramentos possíveis (Cenários 2x2)

- IFTF
- Metodologia clássica da Shell/GBN




- [IFTF - Three Horizons of AI-Enabled Work and Workers](#)
- [IFTF - A Playbook for Ethical Technology Governance](#)

Tendências da IA: O que esperar

Sinais e Possíveis desdobramentos da IA

Desdobramentos possíveis (Cenários 2x2)

- IFTF
- Metodologia clássica da Shell/GBN



H1 — Hoje: IA generativa mainstream, copilotos difundidos, alucinação ainda não resolvida, humano sempre no loop.

H2 — 5 anos: IA agêntica autônoma faz tarefas sozinha (não só aconselha), especialistas viram "versatilistas" apoiados por IA, empresas rodam ecossistemas de modelos (não um só).

H3 — 10+ anos: sistemas de IA redesenham processos inteiros de indústrias, decisão de alto risco ainda exige julgamento humano — mas o "trabalho" muda de natureza.


- [IFTF - Three Horizons of AI-Enabled Work and Workers](#)
- [IFTF - A Playbook for Ethical Technology Governance](#)

4. Tipos de Inteligência Artificial

TIPOS DE IA

Taxinomia Clássica

Exhibit 6: Branches of AI



Source: BofA Merrill Lynch Global Research

via @mikequindazzi

TIPOS DE IA

Por capacidade

Duas taxonomias distintas: o que o sistema alcança e o que o sistema faz.

ESTAMOS AQUI

IA Estreita ANI

Desempenho em tarefas delimitadas. Um sistema traduz, outro dirige, outro escreve — nenhum transfere competência para fora do seu domínio de treino.

100% do que existe hoje, incluindo modelos de fronteira.

HIPOTÉTICO

IA Geral AGI

Competência equivalente à humana em qualquer domínio cognitivo, com transferência de aprendizado entre tarefas não treinadas.

Sem definição operacional consensual — nem teste de aprovação aceito.

ESPECULATIVO

Superinteligência ASI

Desempenho superior ao humano em toda atividade cognitiva, incluindo pesquisa científica e estratégia.

Objeto de discussão filosófica e de política pública, não de engenharia.

Para decisão de negócio, só a primeira coluna importa. As outras duas definem o horizonte de risco, não o escopo de projeto.

TIPOS DE IA

Por função

FUNÇÃO	O QUE FAZ	EXEMPLOS
Percepção	Converte sinal do mundo físico em dado estruturado: imagem, áudio, sensor.	Reconhecimento facial · Inspeção visual industrial
Linguagem	Interpreta, resume e traduz texto e fala; extrai intenção e entidades.	Triagem de contratos · Atendimento conversacional
Previsão	Estima um valor ou probabilidade futura a partir de histórico.	Score de crédito · Previsão de demanda
Decisão e otimização	Escolhe a melhor ação sob restrições, ou aprende por tentativa e erro.	Roteirização logística · Precificação dinâmica
Geração	Produz conteúdo novo — texto, imagem, áudio, código — a partir de instrução.	Redação assistida · Geração de código

Visão computacional, PLN e robótica — os “ramos” das taxonomias clássicas — são combinações dessas funções, não categorias paralelas. As quatro primeiras já estavam em produção há uma década; a última é o que mudou desde 2022.

Discriminativa × Generativa

	Discriminativa	Generativa
PERGUNTA	“A qual categoria isto pertence?”	“Qual é a continuação plausível disto?”
SAÍDA	Um rótulo ou número — verificável contra a resposta correta.	Um artefato novo — sem resposta correta única contra a qual medir.
EXEMPLOS	Detecção de fraude · Diagnóstico por imagem	Redação de minuta · Geração de campanha
IMPLICAÇÃO DE GESTÃO	Métrica objetiva de acurácia; validação estatística padrão.	Exige revisão humana e critério editorial no fluxo de trabalho.

A maior parte do valor capturado por empresas até 2022 vinha da coluna esquerda. A mudança de 2022 em diante não substituiu essa coluna — acrescentou a outra.

IA Generativa por modalidade

MODALIDADE	ARQUITETURA	EXEMPLOS
Texto	Transformer autorregressivo	GPT-4 (2023) · Claude (2024)
Imagem	Modelo de difusão	Stable Diffusion (2022) · Midjourney (2023)
Áudio e voz	Transformer e difusão	Whisper (2022) · ElevenLabs (2023)
Vídeo	Difusão com dimensão temporal	Sora (2024) · Runway Gen-3 (2024)
Código	Transformer especializado	GitHub Copilot (2021) · Cursor (2023)
Multimodal	Transformer nativo multimodal	Gemini (2023) · GPT-4o (2024)

Seis modalidades, duas arquiteturas. Transformer para sequências, difusão para sinal contínuo — e a fronteira entre as duas está se dissolvendo nos sistemas mais recentes.

O que limita a IA generativa

01

Alucinação

O modelo produz afirmações fluentes e falsas com a mesma confiança das corretas. Não há sinal interno que separe as duas.

02

Direitos autorais e dados

Origem do material de treino e titularidade da saída seguem em litígio em várias jurisdições.

03

Custo e energia

Custo por chamada é variável e cresce com o uso. Treinamento e inferência têm pegada energética material.

04

Confidencialidade

Dado colado no prompt sai do perímetro da empresa. Exige política de uso e contrato explícito com o fornecedor.

05

Viés e representação

O modelo reproduz padrões do corpus, inclusive os indesejados, em escala e com aparência de neutralidade.

06


Avaliação

Sem resposta correta única, medir qualidade exige critério humano — o que dificulta prova de ROI.

Nenhum desses itens impede a adoção. Todos determinam onde manter revisão humana no fluxo — e é essa decisão, não a escolha do modelo, que separa piloto de operação.

5. Neurônios Artificiais

Neurônio Artificial: A Unidade Básica das Redes Neurais



Um neurônio artificial é a unidade fundamental de uma rede neural artificial, inspirada no funcionamento dos neurônios biológicos do cérebro humano.

Ele é uma FUNÇÃO MATEMÁTICA que recebe entradas, realiza cálculos e gera uma saída, que pode ser usada por outros neurônios da rede, de forma análoga, e simplificada, de um neurônio biológico. Também são conhecidos como perceptrons.

Neurônio Artificial: A Unidade Básica das Redes Neurais

$$y = f \left(\sum_{i=1}^n w_i x_i + b \right)$$

Onde:

- x_i são os valores de entrada (dados).
- w_i são os pesos associados a cada entrada.
- b é o bias, um ajuste que permite deslocar a função de ativação.
- $f()$ é a função de ativação, que decide se o neurônio “dispara” ou não.
- y é a saída do neurônio.


Dentro desta função tem uma parte linear, simples! O que a torna distinta de uma função linear é a função de ativação $y = f(z)$; Esta função é o neurônio artificial.

A função de ativação permite que o neurônio detecte padrões complexos, ao contrário de um simples modelo linear.

Analogia Simples - Imagine que você é um professor corrigindo provas:

1. Cada ATIVIDADE (REDAÇÃO, TESTE, PROVA DISSERTATIVA) vale um peso diferente (por exemplo, a redação vale mais que o teste de múltipla escolha).
2. Você soma os pontos dos alunos.
3. Se um aluno tiver uma nota total acima de um certo limite (como 60 pontos), ele passa (função de ativação tipo “degrau”).
4. Se a nota for muito baixa, ele reprova.
5. Esse tipo de função matemática permite que redes neurais aprendam a classificar, prever e encontrar padrões em dados.

Neurônio Artificial: A Unidade Básica das Redes Neurais



$$y = f\left(\sum_{i=1}^n w_i x_i + b\right)$$

Onde:

x_i — valores de entrada (dados).

w_i — pesos associados a cada entrada.

b — bias, desloca a função de ativação.

$f()$ — função de ativação: decide se o neurônio “dispara”.

y — saída do neurônio.



A soma ponderada sozinha é só uma função linear. É a função de ativação $f()$ que permite ao neurônio detectar padrões complexos — sem ela, não existe rede neural, só regressão linear.

ANALOGIA SIMPLES

Você, professor, corrigindo provas

1

Atividades com pesos

Redação, teste e prova dissertativa valem pontuações diferentes.

→ 2

Soma dos pontos

Você soma as notas ponderadas de cada aluno.

→ 3

Limite de ativação

Nota total acima de 60? Uma função tipo “degrau” decide.

→ 4

Resultado


Passa ou reprova — um padrão foi classificado.

Esse tipo de função matemática permite que redes neurais **classifiquem, prevejam e encontrem padrões** em dados.

**Demonstrações nos notebooks de
aula!**

6. Redes de Neurônios Artificiais

Redes de Neurônios Artificiais: arquitetura



Os neurônios se conectam em camadas para formar redes:

- Camada de entrada recebe os dados brutos
- Camadas ocultas transformam esses dados em representações cada vez mais abstratas
- Camada de saída produz o resultado final

Redes profundas (muitas camadas) capturam padrões mais complexos; redes largas (mais neurônios por camada) têm maior capacidade de memorização.

Treinamento Supervisionado


Forward propagation (a rede prevê) → cálculo do erro (compara com o rótulo correto) → backpropagation (ajusta os pesos para reduzir o erro).

Treinamento Não Supervisionado

A rede busca padrões e agrupamentos nos dados, sem rótulos conhecidos.

Tipos de Rede Neural

Cada tipo de rede é otimizado para uma classe de problema:



- Feedforward (FFNN)

Informação flui só numa direção; base para arquiteturas mais complexas. Aplicação: classificação, regressão.

- Convolutacional (CNN)

Usa filtros que deslizam sobre a entrada, eficiente para imagens. Aplicação: visão computacional, diagnóstico por imagem.

- Recorrente (RNN)

Tem conexões cíclicas, informações anteriores influenciam o processamento atual. Aplicação: séries temporais, texto.

- LSTM

Evolução da RNN que resolve o desvanecimento do gradiente, "lembra" por mais tempo. Aplicação: sequências longas, tradução automática.

- GANs

Duas redes (gerador e discriminador) competem entre si. Aplicação: geração de dados sintéticos.

- Autoencoders

Aprendem a comprimir e reconstruir dados. Aplicação: redução de dimensionalidade, detecção de anomalias.

Visão geral dos 13 cases de aplicação de negócio

Slide de referência/mapa — inclui todos os 13 notebooks de `aplicacoes-de-negocio/`:

#	Case	Técnica de rede neural	Técnica tradicional (baseline)	Problema que resolve
01	Detecção de fraude	MLPClassifier	Regressão logística	Identificar transações fraudulentas em tempo real
02	Recomendação de produtos	Embeddings / filtragem colaborativa	Média por item	Recomendar produtos personalizados
03	Previsão de demanda	RNN simples	Média móvel	Prever demanda futura de produtos/estoque
04	Chatbot de atendimento	TF-IDF + MLPClassifier	Regra de palavras-chave	Classificar e direcionar solicitações de atendimento
05	Visão computacional em varejo	CNN	Limiar de intensidade	Classificar imagens de produtos/prateleiras
06	Diagnóstico por imagem médica	CNN (uso didático)	Limiar simples	Apoiar triagem diagnóstica por imagem
07	Manutenção preditiva	LSTM	Limiar de vibração	Antecipar falhas de equipamento
08	Precificação dinâmica	MLPRegressor	Regressão linear	Prever o preço ótimo de um produto
09	Score de crédito	MLPClassifier	Regressão logística	Avaliar risco de crédito de um cliente
10	Geração de conteúdo de marketing	GAN pequena	— (caso generativo)	Gerar conteúdo sintético de marketing
11	Prevenção de lavagem de dinheiro	Autoencoder	Z-score	Detectar transações financeiras anômalas
12	People analytics — turnover	MLPClassifier	Regressão logística	Prever risco de saída de colaboradores
13	Mini-LLM com poucos textos	Embedding + LSTM (nível caractere)	— (caso generativo)	Gerar texto a partir de poucos exemplos de treino

Nota: todos os casos usam dados simulados, com métrica de negócio explícita. Os números completos estão no notebook de cada caso.

O que os números realmente mostram

Nem toda rede neural vence o baseline — e isso também é um resultado válido. Cada comparação foi rodada com 3 sementes aleatórias diferentes (não uma vez só), para separar ganho real de sorte da rodada.

Onde a rede neural compensa com folga

- Diagnóstico por imagem — recall quase dobra: 0,54 → 0,88
- Precificação dinâmica — erro cai de ~54 para ~10
- Turnover de pessoas
- Prevenção de lavagem de dinheiro

Onde a vantagem não se sustenta

- Recomendação de produtos — RMSE 1,36 vs 1,35 (empate estatístico)
- Visão computacional em varejo — a CNN varia de 40% a 83% de acurácia dependendo da semente
- Score de crédito — AUC 0,875 vs 0,884 (a rede perde numa das 3 sementes)

Antes de perguntar "qual técnica?", pergunte "esse problema precisa de rede neural, ou um modelo simples já resolve com menos custo e mais previsibilidade?" — vamos aprofundar esse framework de decisão no Bloco B.

Obrigado!

Marco Fidos — Head of IA and Innovation

Próximo bloco: B — Projetos de IA e Desafios Empresariais

Redes Neurais Aplicadas a Negócios — MBA IA & Analytics, FGV

Referências Adicionais

- Marcus, G., & Davis, E. (2019). Rebooting AI: Building Artificial Intelligence We Can Trust. Pantheon Books.
- Garcez, A., et al. (2022). Neurosymbolic AI: The 3rd Wave. Artificial Intelligence Review, 55(6), 4137-4146. DOI: [10.1007/s10462-022-10246-w](https://doi.org/10.1007/s10462-022-10246-w).
- Dehaene, S. (2014). Consciousness and the Brain: Deciphering How the Brain Codes Our Thoughts. Viking Press.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press. www.deeplearningbook.org
- VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly Media. jakevdp.github.io/PythonDataScienceHandbook
- Vaswani, A., et al. (2017). Attention Is All You Need. Advances in Neural Information Processing Systems. arxiv.org/abs/1706.03762
- Devlin, J., et al. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arxiv.org/abs/1810.04805
- Brown, T.B., et al. (2020). Language Models are Few-Shot Learners. Advances in Neural Information Processing Systems. arxiv.org/abs/2005.14165
- Jurafsky, D., & Martin, J.H. (2023). Speech and Language Processing (3ª edição em desenvolvimento). web.stanford.edu/~jurafsky/slp3
- Touvron, H., et al. (2023). LLaMA: Open and Efficient Foundation Language Models. arxiv.org/abs/2302.13971
- Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. arxiv.org/abs/2005.11401