


Redes Neurais Aplicadas a Negócios

MBA em Inteligência Artificial e Analytics Aplicadas a Negócios —
Negócios — FGV

C – Design de Projetos de IA



Abertura, apresentações e Expectativas



Marco Fidos

Head de IA & Innovation, Keyrus

+ 20 anos liderando tecnologia, dados e inovação na América Latina, ele é responsável pela agenda de IA da Keyrus e pelo desenvolvimento de soluções para clientes, unindo uma rara combinação de engenharia, negócio e visão comercial para transformar inteligência artificial em valor real.

- ✓ Membro do CoE AI – Global Keyrus
- ✓ Professor – PUCS, FGV...

EXPERIÊNCIA

- ✓ **Keyrus – Head de IA e Inovação**
- ✓ Atech (Embraer): Gerente Técnico – Soluções de IA, Big Data e Analytics
- ✓ Inovação GIS: +11 anos na direção executiva
- ✓ DigitalGlobe / Maxar: Country Manager LatAm
- ✓ Oficial do Exército

JORNADA

- ✓ Doutorando em Eng. Eletrônica e Computação ITA – Arquitetura de Sistemas de Raciocínio Neuro-Simbólico
- ✓ Mestre em Engenharia de Sistemas Espaciais – INPE
- ✓ MBA Gestão Empresarial – FGV
- ✓ Palestrante: ITA, ECEME, COTER, AI Summit BR, AI Data Leaders...
- ✓ Pesquisador CNPq, ANATEL - Autor de artigos científicos (IEEE - Explainable AI, Machine Learning) e Arquiteturas de Sistemas de Informação

C — Design de Projetos de IA

Coleta e preparação de dados,
calibragem e avaliação

- A — Alinhamento Conceitual

Inteligência, IA, tipos de IA, neurônios artificiais, redes neurais

- B — Projetos de IA e Desafios Empresariais

Exemplos reais de projetos de IA e quando (não) usar IA

- D — Uso de IA Generativa como copiloto

Antigravity, Git/GitHub e Gamma no fluxo de trabalho

- E — Apresentação dos trabalhos finais

Miniprojeto de ML com redes neurais

ROTEIRO

BLOCO B

Nesta aula, construiremos uma compreensão sólida sobre o tema, navegando pelos seguintes tópicos:

Coleta e Preparação de Dados

Criação e Otimização de Modelos

Separação de Dados

Testes e Validações

Seleção de Algoritmos

Entrada em produção - MLOps

Bem-vindos

Marco Fidos


Head of IA and Innovation

- ✓ Quem está na sala?
- ✓ Qual sua experiência prévia com IA e redes neurais?



1. Coleta e Preparação de Dados

Coleta e Preparação de Dados



"Garbage in, garbage out" — nenhum algoritmo, por mais sofisticado, compensa dados mal coletados ou mal preparados.

Problemas mais comuns

- Dados faltantes (campos vazios ou nulos)
- Outliers — valores extremos que distorcem o padrão
- Duplicatas — o mesmo registro contado mais de uma vez
- Formatos inconsistentes (datas, unidades, categorias)
- Viés de amostragem — a base não representa a realidade

Sobre "Bases de Dados"

A base pronta desta etapa ainda não está separada em treino e teste — essa divisão, e os cuidados para fazê-la corretamente (vazamento de dados, séries temporais, validação cruzada), é o tema do próximo slide: Separação de Dados.

2. Separação de Dados

Separação de Dados



Proporção típica — pode variar conforme o tamanho da base (ex.: 80/10/10 em bases muito grandes).

⚠ Vazamento de dados (data leakage)

Quando informação do conjunto de teste "vaz" para o treino — direta ou indiretamente — o modelo parece ótimo no teste e falha na produção. Sempre separe antes de qualquer transformação que aprenda com os dados (normalização, imputação).

Dados temporais: não embaralhe

Se a base é uma série temporal (vendas, sensores, transações ao longo do tempo), a separação precisa respeitar a ordem cronológica — treine no passado, teste no futuro. Embaralhar aleatoriamente cria um vazamento disfarçado.

Validação cruzada (k-fold) — quando a base é pequena



A cada rodada, um "pedaço" diferente vira teste — ao final, todo o dado foi testado uma vez, sem desperdiçar amostras.

Por que isso importa: a separação de dados é o que garante que a métrica do próximo slide (Testes e Validações) reflete o desempenho real do modelo em dados que ele nunca viu — não um número inflado por vazamento ou embaralhamento indevido.

3. Seleção de Algoritmos

Seleção de Algoritmos

Depois de escolher a família de técnica certa (Bloco B), estes critérios ajudam a escolher a implementação específica.

1

Tamanho do dataset

Poucos dados favorecem modelos simples; redes profundas precisam de volume.

2

Interpretabilidade exigida

Crédito e saúde, por exemplo, costumam exigir modelos explicáveis.

3

Custo computacional

Treino e inferência têm custo — meça contra o orçamento disponível.

4

Tempo de treinamento

Modelos complexos podem levar horas ou dias para treinar de novo.

Regra prática: comece sempre por um baseline simples. Se ele já resolve, um modelo mais complexo só se justifica se o ganho superar o custo — os 3 cases do Bloco B mostram isso com números reais.

4. Criação e Otimização de Modelos de IA

Criação e Otimização de Modelos



5. Testes, Validações e Otimização (Hiperparâmetros)

Testes e Validações

Classificação

Acurácia	% de prev isões corretas no total.
Precisão	das previsões positivas, quantas eram de fato positivas.
Recall	dos casos positivos reais, quantos o modelo capturou.
F1-score	média harmônica entre precisão e recall.
AUC-ROC	capacidade de separar as classes em todos os limiares.

Regressão

MAE	erro médio absoluto — em unidades originais, fácil de interpretar.
RMSE	penaliza mais os erros grandes que o MAE.
R²	quanto da v ariação dos dados o modelo ex plica (0 a 1).


Nenhuma métrica sozinha conta a história toda — combine mais de uma e escolha a que reflete o custo real de errar no seu problema (ex.: em fraude, recall costuma pesar mais que acurácia).

Sempre compare contra o baseline: uma métrica só tem significado ao lado da alternativa mais simples — é assim que os 3 cases do Bloco B rev elaram onde a rede neural não v alia o custo.

Hiperparametrização: Otimização de Modelos


Parâmetro x hiperparâmetro — parâmetros (pesos, bias) são aprendidos durante o treino; hiperparâmetros são escolhidos antes de treinar e moldam como esse aprendizado acontece.

Grid Search




Testa todas as combinações de um conjunto fixo de valores — cobertura completa, mas custo exponencial.

Random Search



Amostra combinações aleatórias do espaço de busca — acha boas soluções com muito menos tentativas.

Otimização Bayesiana



Usa os resultados de cada tentativa para focar a busca nas regiões mais promissoras do espaço.

Hiperparâmetros mais comuns em redes neurais

Taxa de aprendizado

Tamanho do passo de ajuste dos pesos — alta demais diverge, baixa demais é lenta.

Tamanho do batch

Exemplos por atualização — afeta velocidade e estabilidade do treino.

Número de épocas

Quantas vezes o modelo vê o dataset — demais leva a overfitting.

Camadas e neurônios

Definem a capacidade do modelo — mais complexidade nem sempre é melhor.

Taxa de dropout

Fração de neurônios desligados a cada rodada, reduzindo overfitting.

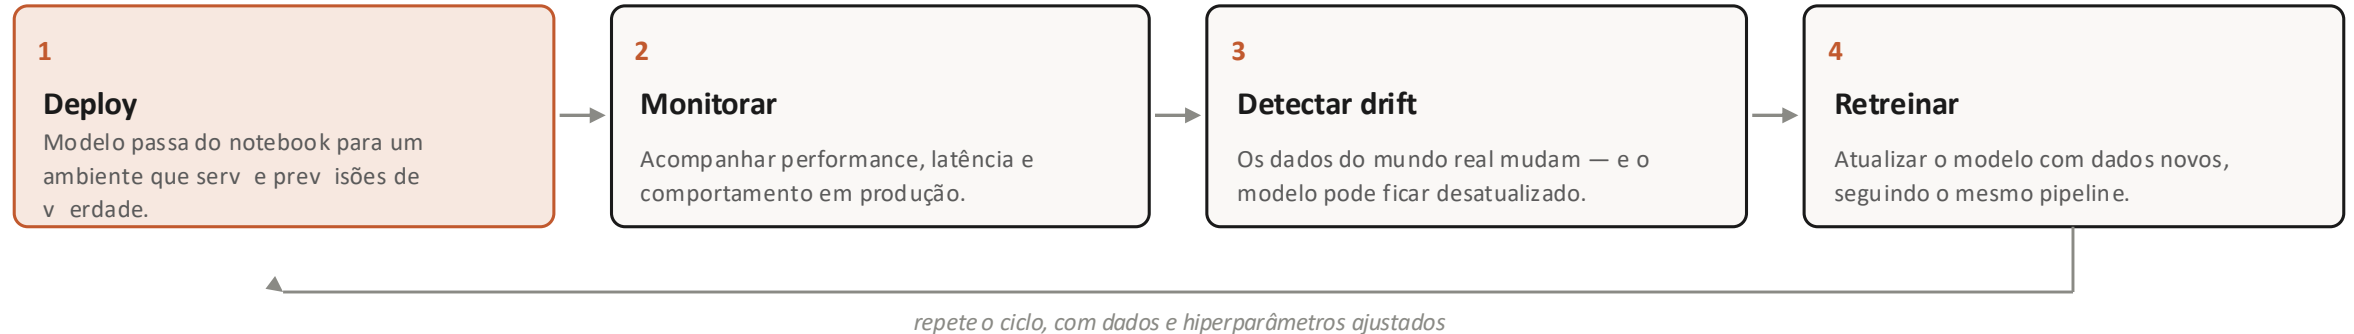
Força de regularização (L1/L2)

Penaliza pesos grandes, controlando o quanto o modelo se simplifica.

Custo x benefício: cada tentativa de hiperparâmetros é um treino completo — a busca tem custo computacional e deve ser validada com o mesmo cuidado (k-fold, baseline) do slide anterior.

6. Entrando em produção - MLOps

Entrada em Produção: MLOps



Por que modelos degradam

O mundo muda depois que o modelo é treinado: novos padrões de fraude, mudança de comportamento de consumo, sazonalidade. Isso é chamado de model drift — e é normal, não uma falha pontual.

Governança mínima em produção

Versionamento — De modelo e de dados, para saber exatamente o que está em produção.

Logging — Registrar previsões e decisões para auditoria futura.

Plano de rollback — Voltar à versão anterior rapidamente se algo falhar.

OBRIGADO!

Marco Fidos

Head of IA and Innovation

Marco.fidos@Keyrus.com.br