

Arquitetura e Planejamento: Projeto Lumina - Diagnóstico e Portabilidade Inteligente de Crédito

1. Visão Geral do Problema e Objetivo

O Problema

A Lumina é uma fintech brasileira em estágio de validação de mercado que oferece saúde financeira como benefício corporativo para empresas contratantes que pagam uma mensalidade por colaborador (modelo B2B2C). O diferencial do produto é a abordagem Rate First, Payoff Second: diagnosticar contratos de crédito ativos (empréstimo consignado, financiamento de veículos e crédito imobiliário) com taxas acima do mercado e orientar o trabalhador CLT a buscar a portabilidade antes de estruturar o plano de quitação de dívidas.

O principal gargalo operacional do produto está na assertividade da recomendação: quando o usuário cadastra seus contratos, a Lumina precisa estimar se uma tentativa de portabilidade resultará em economia real e aceitação no mercado. Errar essa previsão tem custos fortemente assimétricos: 1. Falso positivo (recomendar portabilidade que o mercado não aceita em condições melhores): o trabalhador tenta a portabilidade, sofre recusa ou não obtém ganho financeiro real, frustra-se e perde a confiança no diagnóstico da Lumina, que é o coração do produto. 2. Falso negativo (deixar de recomendar uma portabilidade viável): o trabalhador segue pagando juros abusivos, e a Lumina falha na entrega de valor prometida à empresa contratante do benefício.

Diferente de um banco tradicional, onde o custo do erro se traduz em provisão para devedores duvidosos (inadimplência/calote), na Lumina o custo do erro reside na perda de confiança do usuário e no churn do benefício corporativo.

Objetivo da IA

Classificar e estimar a probabilidade de um contrato de crédito ativo resultar em portabilidade aceita e economicamente vantajosa, calibrando a recomendação para maximizar a precisão e gerar justificativas claras e transparentes para o trabalhador.

Métrica de Sucesso (Negócio)

Como a Lumina está em estágio de validação e não possui histórico volumétrico para estabelecer baselines consolidados, as metas são declaradas explicitamente como hipóteses iniciais a validar:

- **Hipótese 1:** Taxa de sucesso das portabilidades recomendadas superior a 80% (alta precisão para preservar a confiança no diagnóstico).
- **Hipótese 2:** Churn anual de empresas contratantes do benefício corporativo abaixo de 10%, sustentado pela percepção de valor e economia real gerada para os colaboradores.
- **Hipótese 3:** Engajamento ativo no diagnóstico superior a 60% dos colaboradores cadastrados nas empresas clientes.
- **Hipótese 4:** Receita retida anual por cliente de R\$ 135.000 (500 colaboradores x R\$ 25 x 12 x 90% de retenção).

2. Coleta e Preparação de Dados

Fase Atual (MVP)

- **Fontes de dados:**
 - Cadastro manual de contratos pelo próprio usuário no aplicativo web/mobile (tipo de contrato, taxa de juros contratada, saldo devedor aproximado, prazo restante e renda mensal informada), com validação de faixas plausíveis por modalidade na interface.
 - Tabelas públicas de taxas médias de juros por modalidade disponibilizadas pelo Banco Central do Brasil em dados abertos (sem SCR e sem integrações de Open Finance).
- **Qualidade dos dados:**
 - Validação de faixas plausíveis na entrada do formulário (exemplo: limites normativos para consignado CLT, prazos máximos para veículos e limites de comprometimento de renda).
 - Tratamento de campos nulos com obrigatoriedade na coleta e verificações de consistência (sanity checks) na camada de aplicação.
- **Engenharia de features:**
 - Spread de taxa em relação à média de mercado do BACEN ($\text{taxa_atual_am} - \text{taxa_referencia_mercado}$).
 - Estimativa simplificada de comprometimento de renda (parcela estimada dividida pela renda declarada).
 - Termo de interação central entre spread, prazo restante e saldo devedor para representar a diluição de atritos e custos operacionais de transação.
 - One-hot encoding para a variável categórica tipo_contrato (consignado, veiculo, imobiliario) com `drop_first=True`.

Visão de Escala

- Integração com Open Finance Brasil via APIs reguladas para extração automática e padronizada de saldos, taxas efetivas (CET) e cronogramas de amortização.
- Integração direta com sistemas de folha de pagamento e RH (ERP/HRIS) para captura automática de margem consignável, renda líquida e tempo de vínculo empregatício.
- Módulo de OCR para leitura de contratos e extratos bancários (CCB).
- Evoluções condicionadas a volume real de usuários e tração do negócio.

3. Estratégia de Bases e Separação de Dados

Fase Atual (MVP)

- **Armazenamento:**
 - Banco de dados relacional PostgreSQL gerenciado no Supabase, aproveitando a mesma infraestrutura do produto.
 - Isolamento e anonimização de identificadores pessoais (CPF, nome, e-mail) para a camada de modelagem e análise, em estrita conformidade com a LGPD.
- **Metodologia de split:**
 - Divisão estratificada (75% treino e 25% teste) com preservação da proporção de portabilidades vantajosas em cada partição.
- **Prevenção de vazamento (Data Leakage):**

- Ajuste (fit) de todos os transformadores (StandardScaler e encoders) estritamente no conjunto de treino.
- Taxas de mercado públicas associadas ao contrato fixadas na data de simulação, sem uso de indicadores futuros.

Visão de Escala

- Estruturação de Data Lakehouse (S3 ou GCS com Delta Lake / Parquet) com camadas Raw, Bronze, Silver e Gold.
- Feature Store centralizada para reuso de atributos em tempo real e batch.
- Validação temporal automatizada por safras de contratos (Out-of-Time Split) para acompanhar ciclos macroeconômicos e variações da taxa Selic.
- Evolução condicionada ao aumento volumétrico de dados históricos.

4. Seleção de Algoritmos

Modelo Baseline

- **Regressão Logística:** modelo linear clássico, rápido de treinar, estável e com interpretabilidade direta através de seus coeficientes. Serve como referência obrigatória de desempenho e transparência.

Modelos Candidatos Testados

- **Rede Neural Perceptron Multicamadas (MLPClassifier):** arquitetura feedforward com duas camadas ocultas (16 e 8 neurônios) e ativação ReLU. Testada no notebook 14 para avaliar a capacidade de capturar interações não lineares entre taxas, saldos e prazos sem engenharia manual prévia.
- **Resultados obtidos na validação multi-seed (seeds 42, 7 e 123):** o MLP obteve AUC-ROC médio de 0,883 +- 0,010 contra 0,861 +- 0,011 da Regressão Logística. Na seed 123, os modelos empataram tecnicamente (0,876 vs 0,873), indicando que o ganho é modesto e sensível à partição amostral.

Modelos Candidatos Futuros (Não Testados)

- **LightGBM / XGBoost:** algoritmos de Gradient Boosting baseados em árvores, planejados para avaliação futura caso o volume de dados e o número de variáveis cadastrais aumentem significativamente.

Decisão Técnica Registrada

Enquanto a vantagem de performance de modelos não lineares (como MLP ou Gradient Boosting) for modesta e não consistente entre sementes, a Regressão Logística calibrada permanece como a escolha oficial de produção. Para a Lumina, a explicabilidade da recomendação em linguagem simples para o trabalhador é um requisito central de produto, superando ganhos marginais de métricas em modelos de caixa-preta.

5. Estratégia de Treinamento e Otimização

Função de Custo (Loss Function)

- **Log-Loss (Binary Cross-Entropy):** minimização do erro de entropia cruzada para predição de probabilidades.
- **Calibração de Probabilidades Pós-Treino:** aplicação de Platt Scaling (regressão logística sobre as saídas) ou Regressão Isotônica para garantir que uma probabilidade estimada de 80% corresponda

efetivamente a 80% de chance de portabilidade bem-sucedida.

Otimização de Hiperparâmetros

- **Busca em Grade (GridSearchCV) ou Random Search:** sintonia de regularização L2 (parâmetro C na Regressão Logística) e arquitetura/taxa de aprendizado no MLP com validação cruzada estratificada em 5 folds.

6. Testes, Validação e Métricas

Métricas de Avaliação Técnica

- **AUC-ROC:** métrica principal para avaliar a capacidade de ordenação de risco e separação entre contratos vantajosos e desvantajosos.
- **Brier Score:** métrica de calibração de probabilidade para avaliar a precisão das probabilidades estimadas (quanto mais próximo de 0, melhor a calibração).
- **Precisão e Recall no Limiar Operacional:** monitoramento do trade-off entre capturar oportunidades e evitar recomendações erradas.

Matriz de Confusão e Impacto no Negócio

Classificação do Modelo	Realidade de Mercado: Inviável	Realidade de Mercado: Vantajosa
Predição: Não Recomendar (0)	Verdadeiro Negativo: Usuário é direcionado para plano de quitação sem frustração.	Falso Negativo: Oportunidade perdida; trabalhador segue com juros altos (Impacto Moderado).
Predição: Recomendar (1)	Falso Positivo: Frustração do usuário, descrédito no diagnóstico Lumina, risco de churn B2B (Impacto Crítico).	Verdadeiro Positivo: Economia real gerada, validação do produto e recomendação espontânea.

Ajuste de Limiar Operacional: O ponto de corte de probabilidade é calibrado para priorizar alta precisão, evitando disparar recomendações de portabilidade duvidosas.

Explicabilidade Nativa (Requisito de Produto)

O modelo precisa alimentar mensagens diretas no aplicativo que expliquem o motivo do diagnóstico, tais como:

"Identificamos que sua taxa atual de 2,2% a.m. está 0,75 ponto percentual acima da taxa média de mercado para crédito consignado. Como ainda restam 42 parcelas sobre um saldo de R\$ 18.000, a portabilidade pode economizar cerca de R\$ 2.900 ao longo do contrato."

Testes de Robustez e Generalização

- Validação multi-seed com pelo menos 3 sementes (42, 7 e 123) em todas as comparações de modelos para verificar consistência e desvio-padrão dos resultados.

7. MLOps: Deploy e Monitoramento

Fase Atual (MVP)

- **Estratégia de implantação:**
- Arquitetura serverless enxuta e alinhada à stack atual da Lumina (Supabase, Netlify Functions e Claude API).
- O modelo treinado e calibrado (Regressão Logística) é serializado em formato leve e executado diretamente dentro de uma Netlify Function.
- Sem necessidade de containers Docker dedicados, servidores permanentes ou orquestradores de infraestrutura (como Kubernetes).
- **Monitoramento contínuo:**
- Processo manual mensal de revisão: cruzamento entre os diagnósticos emitidos no app e os desfechos reportados pelos próprios usuários e pelas empresas parceiras.
- Acompanhamento da taxa de conversão real e das razões de recusa reportadas.
- **Gatilho de retreino:**
- Queda da taxa de sucesso das recomendações superior a 5 pontos percentuais em relação à baseline de lançamento, medida na revisão mensal, ou atualização relevante das tabelas de taxas médias do BACEN. Cadência de retreino distinta do monitoramento: reavaliação trimestral programada do modelo, mesmo sem gatilho disparado.

Visão de Escala

- Microserviço dedicado de inferência em tempo real utilizando FastAPI e empacotamento em containers gerenciados.
- Pipelines de processamento em lote para reanálise periódica automatizada de toda a carteira de contratos da base.
- Monitoramento contínuo de Data Drift e Concept Drift com ferramentas automatizadas (como Evidently AI).
- Pipeline de retreinamento automatizado com testes de regressão antes do deploy contínuo (CI/CD de ML).
- Evoluções condicionadas a tração de mercado e volume real de contratos analisados.

8. Viabilidade Econômica (ROI)

Todas as premissas econômicas abaixo são declaradas explicitamente como hipóteses iniciais a validar:

Premissas de Receita

- **Perfil de cliente ilustrativo:** empresa contratante com 500 colaboradores CLT.
- **Ticket médio por colaborador:** R\$ 25/colaborador/mês (ponto médio da faixa de precificação B2B2C de R\$ 15 a R\$ 40).
- **Receita bruta anual por empresa cliente:** 500 colaboradores x R\$ 25 x 12 meses = R\$ 150.000.

Premissas de Valor Entregue (Economia aos Colaboradores)

- **Elegibilidade:** 20% dos colaboradores possuem contratos de crédito ativos em condições portáteis (100 colaboradores).
- **Taxa de conversão das recomendações:** 80% dos colaboradores elegíveis concluem a portabilidade (80 contratos portados por empresa/ano).
- **Economia financeira média:** R\$ 2.900 economizados ao longo do contrato por portabilidade concluída.
- **Valor financeiro total devolvido por empresa/ano:** $500 \times 0,20 \times 0,80 \times \text{R\$ } 2.900 = \text{R\$ } 232.000$.

Estrutura de Custos (Estimativas Declaradas)

- **Custo de Construção (Estimativa Declarada):**
 - 40 horas de desenvolvimento a R\$ 150/hora = R\$ 6.000.
 - Infraestrutura serverless no tier gratuito (Supabase e Netlify), resultando em custo marginal aproximadamente zero neste estágio.
 - Custo total de construção: R\$ 6.000.
- **Custo de Sustentação (Estimativa Declarada):**
 - Revisão manual mensal de 4 horas a R\$ 150/hora = R\$ 600/mês = R\$ 7.200/ano.
 - Custo computacional de inferência: desprezível (modelo de Regressão Logística serializado em Netlify Function).
 - Custo total de sustentação anual: R\$ 7.200/ano.
- **Custo Total no Primeiro Ano (Construção + Sustentação):** $\text{R\$ } 6.000 + \text{R\$ } 7.200 = \text{R\$ } 13.200$.

Comparação Custo vs. Retorno (ROI e Payback)

- **Retorno sobre o Investimento (ROI):**
 - Fórmula: $\text{ROI} = (\text{retorno} - \text{custo}) / \text{custo}$.
 - Calculado sobre a receita de um único cliente B2B2C no primeiro ano: $(\text{R\$ } 150.000 - \text{R\$ } 13.200) / \text{R\$ } 13.200 = 10,36$ (1.036% de retorno sobre o investimento).
 - Calculado sobre a receita líquida retida de um cliente (considerando 10% de churn): $(\text{R\$ } 135.000 - \text{R\$ } 13.200) / \text{R\$ } 13.200 = 9,23$ (923% de retorno).
- **Payback em Meses:**
 - Receita mensal gerada por uma empresa cliente: $500 \text{ colaboradores} \times \text{R\$ } 25 = \text{R\$ } 12.500/\text{mês}$.
 - Payback do custo de construção inicial: $\text{R\$ } 6.000 / \text{R\$ } 12.500 = 0,48$ mês (~15 dias).
 - Payback do custo total anual (incluindo sustentação): $\text{R\$ } 13.200 / \text{R\$ } 12.500 = 1,06$ mês (~32 dias).

Métrica de Negócio Consolidada

- **Fórmula:** $\text{receita_retida} = \text{ticket} \times \text{colaboradores} \times 12 \times (1 - \text{churn})$.
- **Projeção com as metas do plano (churn 10%):** $\text{R\$ } 25 \times 500 \text{ colaboradores} \times 12 \text{ meses} \times (1 - 0,10) = \text{R\$ } 135.000$ de receita retida anual por cliente.