

Arquitetura e Planejamento: Projeto Detecção de Fraude em Transações Financeiras

Documento de Engenharia e Design de Solução de IA | MBA em Inteligência Artificial para Negócios — FGV

Autor: Renan Marchini Andrusiac Vieira

Repositório: [renan-marchini/FGV-aulas](https://github.com/renan-marchini/FGV-aulas)

Notebook de Referência: [aplicacoes-de-negocio/01-deteccao-fraude.ipynb](#)

1. Visão Geral do Problema e Objetivo

1.1 O Problema de Negócio

Instituições financeiras e plataformas de pagamentos digitais enfrentam um duplo desafio crítico na gestão de transações com cartão de crédito e pagamentos instantâneos:

- 1. Perdas Diretas por Fraude (Falsos Negativos):** Cada transação fraudulenta aprovada indevidamente acarreta prejuízo direto de reembolso ao cliente lesado (*chargeback*), multas regulatórias e custo administrativo de auditoria. Custo unitário estimado: **R\$ 1.500,00 por ocorrência.**
- 2. Atrito e Perda de Clientes por Falsos Alarmes (Falsos Positivos):** Sistemas antifraude legados, fundamentados em regras estáticas simples (ex.: valor alto ou horário atípico isolados), bloqueiam transações de clientes legítimos. Isso gera sobrecarga nas centrais de atendimento (*call center*), frustração do consumidor e risco elevado de cancelamento de cartão (*churn*). Custo unitário estimado de suporte e atrito: **R\$ 100,00 por ocorrência.**

1.2 Objetivo da IA

Desenvolver, treinar e implantar um modelo preditivo supervisionado de Inteligência Artificial baseado em **Redes Neurais Artificiais (Multi-Layer Perceptron - MLP)** capaz de estimar em tempo real a probabilidade de uma transação ser fraudulenta ($y=1$) ou legítima ($y=0$), capturando automaticamente interações não lineares complexas entre múltiplos atributos transacionais e comportamentais.

1.3 Métrica de Sucesso de Negócio e Viabilidade Econômica (ROI)

- Métrica Técnica Principal:** Maximizar o **F1-Score da classe de fraude** (> 0.20) e a **Precisão** (> 0.13), mantendo o **Recall balanceado** ($> 50\%$) na validação multi-seed, eliminando 100% de colapsos de modelo.
- Métrica de Sucesso Financeiro:** Minimizar o **Custo Total de Negócio**
$$\text{Custo Total} = (\text{FN} \times \text{R}) \times 1.500 + (\text{FP} \times \text{R}) \times 100$$
- Economia no Conjunto de Teste (6.000 transações):** O modelo proposto atinge custo de **R\$ 238.600,00** (com threshold ótimo 0.80), economizando **R\$ 52.800,00** em relação ao baseline de Regressão Logística (R\$ 291.400,00) e **R\$ 129.700,00** em relação à regra determinística (R\$ 368.300,00).

Demonstrativo de ROI e Viabilidade Econômica (Cenário Operacional: 1.000.000 transações/mês)

Linha Orçamentária / Indicador	Discriminação / Detalhamento	Valor (R\$)
Custo de Construção (Capex)	1 ML Engineer Sênior + 1 Data Engineer (2 meses) + Infraestrutura de treino/Cloud	R\$ 65.000,00
Custo de Sustentação Anual (Opex)	Infraestrutura Cloud (API Server + Redis + Observabilidade) + 15% Engenharia para retreino	R\$ 54.000,00/ano
Investimento Total no 1º Ano	Capex (R\$ 65k) + Opex Anual (R\$ 54k)	R\$ 119.000,00
Retorno Financeiro Bruto Projetado	Economia anual de perdas por fraude e redução de falsos alarmes em produção	R\$ 504.000,00/ano
Retorno Líquido no 1º Ano	Benefício Bruto Anual - Custo Total 1º Ano (R\$ 504.000 - R\$ 119.000)	R\$ 385.000,00
Retorno sobre o Investimento (ROI)	$(504.000 - 119.000) / 119.000$	+323,5%

Prazo de Retorno (Payback)	Recuperação integral do Capex + Opex acumulado	2,8 meses
Ponto de Equilíbrio (Breakeven)	Atingido no 1º trimestre de operação em produção	Mês 3

2. Coleta e Preparação de Dados

2.1 Fontes de Dados e Atributos Transacionais

Os dados são originados de três barramentos de mensageria em tempo real:

- **Gateway de Pagamentos:** Valor da transação monetária e *timestamp* da solicitação.
- **Sistemas de Segurança e Sessão:** Identificador de dispositivo (*fingerprint* do aparelho / app mobile), indicador de novo dispositivo e geolocalização estimada via IP/GPS.
- **Cadastro e Histórico Comportamental do Cliente:** Frequência de compras recentes e distância média do local habitual de consumo.

2.2 Dicionário de Features

Variável	Tipo	Descrição e Distribuição
valor_transacao	Númerica Contínua	Valor em reais da transação (distribuição exponencial, média R\$ 260,00).
hora_do_dia	Númerica Inteira	Hora da transação entre 0 e 23h (distribuição uniforme).
distancia_do_local_habitual_km	Númerica Contínua	Distância euclidiana em km em relação ao padrão habitual do cliente.
transacoes_ultimas_24h	Númerica Inteira	Contagem de transações nas 24h precedentes (distribuição de Poisson, $\lambda=3$).
dispositivo_novo	Catégorica Binária	1 se o dispositivo não consta no histórico do cliente; 0 caso conhecido ($p=15\%$).
fraude (Target)	Catégorica Binária	1 para transação fraudulenta confirmada; 0 para transação legítima (~4,16% de fraudes).

2.3 Engenharia de Features e Relações Não Lineares

O score latente de risco de fraude incorpora interações cruzadas não lineares:

- **hora_madrugada:** Flag binária indicando operações entre 00:00 e 05:59.
- **muitas_transacoes:** Flag indicando frequência transacional elevada (≥ 6 transações nas últimas 24h).
- **Interação Tripla Não Linear:** Combinação simultânea de **valor_transacao** elevado $\times$ **dispositivo_novo** $\times$ **distancia_do_local_habitual_km**.
- **Interações Duplas:** Dispositivo novo durante a madrugada e valor alto sob alta frequência.

2.4 Tratamento de Desbalanceamento Severo

Com apenas ~4,16% de fraudes, o modelo neural tradicional colapsaria prevendo sempre zero. Aplicou-se **Oversampling com Reposição da classe minoritária** (`y_train == 1`) exclusivamente sobre o conjunto de treino até atingir a proporção 50%/50%.

3. Estratégia de Bases e Separação de Dados

3.1 Armazenamento e Governança

- **Camada Raw (Data Lake):** Eventos brutos armazenados em Cloud Storage (formato Parquet colunar particionado por data).
- **Camada Curada (Feature Store):** Tabela analítica agregada com features comportamentais de baixa latência (Redis / Feast).

3.2 Metodologia de Split

- Divisão estratificada: **70% para Treinamento (14.000 amostras)** e **30% para Teste (6.000 amostras)** via `train_test_split(stratify=y, random_state=42)`.
- A estratificação garante idêntica proporção de fraudes (~4,16%) em ambos os conjuntos.

3.3 Prevenção Rigorosa de Vazamento de Dados (Data Leakage)

1. **Isolamento de Padronização:** O normalizador `StandardScaler` é ajustado (*fit*) estritamente com os dados de treino `X_train`. A transformação resultante é aplicada sem reajuste em `X_test`.
2. **Isolamento de Reamostragem:** O Oversampling é executado apenas sobre as linhas de treino já separadas. O conjunto de teste jamais recebe dados sintéticos ou duplicados, preservando a fidelidade da distribuição real de mercado.

4. Seleção e Comparação de Algoritmos

Comparamos quatro abordagens conceituais para avaliar empiricamente a necessidade de IA e o ganho marginal de cada técnica:

```
[Fluxo Transacional] ---> [1. Regra Determinística] (Regra estática de corte linear)
                        ---> [2. Regressão Logística] (Baseline linear ponderado)
                        ---> [3. MLP Sem Balanceamento] (Rede neural pura - colapsa no desbalanceamento)
                        ---> [4. MLP com Oversampling] (Rede neural com treino balanceado e threshold ótimo)
```

1. **Benchmark 1: Regra Determinística Heurística:** Regra estática comumente usada em sistemas tradicionais: bloqueia se `valor > R$ 1.000` OU (`distancia > 50km` E `madrugada`).
2. **Benchmark 2: Regressão Logística (`class_weight='balanced'`):** Modelo linear clássico que compensa o desbalanceamento ponderando inversamente as classes na função de verossimilhança.
3. **Benchmark 3: Rede Neural MLP Sem Balanceamento:** Arquitetura MLP de duas camadas ocultas (16, 8) com ativação ReLU treinada na proporção original.
4. **Modelo Proposto: Rede Neural MLP com Oversampling no Treino:** A mesma arquitetura neural treinada com reamostragem balanceada no treino e sintonia de threshold de decisão.

5. Estratégia de Treinamento e Otimização

- **Arquitetura da Rede:** Multi-Layer Perceptron (MLP) com entrada de 5 dimensões $\rightarrow$ Camada Oculta 1 (16 neurônios, ReLU) $\rightarrow$ Camada Oculta 2 (8 neurônios, ReLU) $\rightarrow$ Camada de Saída (1 neurônio sigmoidal com probabilidade de fraude).
- **Função de Perda (Loss Function):** *Binary Cross-Entropy Loss* (Log-Loss):

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right]$$

- **Algoritmo de Otimização:** `Adam` com taxa de aprendizado inicial $\alpha = 0.001$, regularização L_2 ($\alpha_{\text{reg}} = 0.0001$) e convergência antecipada (*Early Stopping*) baseada em monitoramento de validação para mitigar sobreajuste (*overfitting*).

6. Testes, Validação e Métricas

6.1 Resultados na Seed 42 (Conjunto de Teste: 6.000 transações)

Modelo	Precisão	Recall	F1-Score	Falsos Positivos (FP)	Falsos Negativos (FN)	Custo Total (R\$)
Sem Modelo (Aprovar Tudo)	0,000	0,000	0,000	0	250	R\$ 375.000,00
1. Regra Determinística	0,089	0,056	0,069	143	236	R\$ 368.300,00
2. Regressão Logística (Baseline)	0,096	0,596	0,166	1.399	101	R\$ 291.400,00
3. MLP Sem Balanceamento	0,545	0,048	0,088	10	238	R\$ 358.000,00
4. MLP + Oversampling (Limiar 0.50)	0,129	0,504	0,205	852	124	R\$ 271.200,00
5. MLP + Oversampling (Limiar Ótimo 0.80)	0,401	0,404	0,402	151	149	R\$ 238.600,00

6.2 Validação Multi-Seed (Robustez Estatística nas Seeds 42, 7 e 123)

Modelo Avaliado	Precisão Média $\pm$ dp	Recall Médio $\pm$ dp	F1-Score Médio $\pm$ dp	Taxa de Colapso
Regra Determinística	\$0,074 $\pm$ 0,013\$	\$0,049 $\pm$ 0,007\$	\$0,059 $\pm$ 0,009\$	0% (Inútil)
MLP Sem Balanceamento	\$0,182 $\pm$ 0,315\$	\$0,016 $\pm$ 0,028\$	\$0,029 $\pm$ 0,051\$	66,7% (2 de 3 seeds)
Regressão Logística (Baseline)	\$0,096 $\pm$ 0,002\$	\$0,607 $\pm$ 0,013\$	\$0,166 $\pm$ 0,002\$	0%
MLP com Oversampling (Proposto)	\$0,138 $\pm$ 0,019\$	\$0,514 $\pm$ 0,009\$	\$0,217 $\pm$ 0,024\$	0% (100% estável)

6.3 Discussão Honesta do Trade-off de Precisão vs Recall


- O Baseline linear possui recall bruto superior no limiar padrão de 0.50 (\$60,7\%\$ vs \$51,4\%\$), porém com precisão inaceitável de \$9,6\%\$, inundando o suporte com quase 1.400 falsos alarmes.
- O MLP com Oversampling eleva a precisão em **+43,8%** e o F1 em **+30,7%**, cortando centenas de falsos positivos.
- Ao otimizar o limiar de decisão (*threshold*) para a realidade financeira (\$FN = 1.500\$ vs \$FP = 100\$), o limiar ótimo de **0.80** minimiza a perda combinada de negócio, atingindo o custo mínimo absoluto de **R\$ 238.600,00**.

7. MLOps: Deploy, Monitoramento e Governança

7.1 Arquitetura de Implantação e SLA de Produção

- **Microserviço de Inferência em Tempo Real:** API REST construída em Python com **FastAPI** empacotada em contêineres **Docker**, orquestrada via Kubernetes (AWS EKS / GCP GKE) com *auto-scaling* horizontal.
- **SLA de Latência:** Inferência executada em **< 30ms (p95)** por requisição transacional.
- **Feature Store Online:** Redis em memória com cache pré-computado das features comportamentais (`transacoes_ultimas_24h`, `distancia_do_local_habitual_km`), garantindo latência de consulta sub-milissegundo (< 2ms).





7.2 Monitoramento Contínuo e Drift

1. Data Drift (Desvio de Distribuição dos Dados de Entrada):

- Monitoramento contínuo das variáveis numéricas via teste de Kolmogorov-Smirnov (KS-Test) e *Population Stability Index* (PSI).
- Alerta disparado se $\text{PSI} > 0.25$ em features críticas como `valor_transacao` ou `distancia_do_local_habitual_km`.

2. Concept Drift (Degradação da Relação Padrão-Fraude):

- *Feedback Loop* semanal consolidando contestações e contestações confirmadas de *chargeback* (janela de maturação de 15 a 30 dias).
- Acompanhamento semanal da taxa de Falsos Positivos reportados no canal de atendimento.

7.3 Política de Retreinamento e Ciclo de Vida do Modelo

- **Retreino Programado:** Mensal, incorporando os dados rotulados dos últimos 90 dias com janelas deslizantes.
- **Retreino Reativo:** Disparado automaticamente se o PSI ultrapassar 0.25 ou se o Recall estimado no pós-audit cair mais de 5 pontos percentuais.
- **Estratégia de Rollout Seguro:**
 - **Fase 1 (Homologação):** Validação técnica em ambiente de *staging*.
 - **Fase 2 (Shadow Mode):** Modelo roda em paralelo com a regra existente por 2 semanas, sem intervir na decisão, para aferição de latência real e taxa de concordância.
 - **Fase 3 (Canary / Rollout Gradual):** Liberação progressiva (10% $\rightarrow$ 25% $\rightarrow$ 50% $\rightarrow$ 100% do tráfego).

7.4 Governança, Segurança e Plano de Contingência (Circuit Breaker)

- **Fallback Automático:** Caso a API atinja tempo de resposta $> 50\text{ms}$ ou indisponibilidade de contêiner, um *Circuit Breaker* direciona o fluxo imediatamente para a regra heurística determinística de contingência, garantindo disponibilidade de 99,99%.
- **Explicabilidade (XAI):** Geração de SHAP values para auditoria interna e justificativa regulatória de bloqueios perante o Banco Central e LGPD.