

Arquitetura e Planejamento: People Analytics com Redes Neurais

O Fim da Evasão Inesperada de Talentos — Modelagem Preditiva com MLP | Aluno: Ney Penalva Filho

DISCIPLINA

Redes Neurais Aplicadas a Negócios

AUDITORIA COMPLETA

Threshold Tuning | Multi-Seed | PSI Condicional

RECONCILIAÇÃO MATEMÁTICA

Turnover 21,0% | Retorno R\$ 1,2M | Payback 1,84m

1 Visão Geral do Problema, Objetivos e Conciliação Financeira

O Problema: O desligamento voluntário de colaboradores estratégicos impõe severas perdas de capital intelectual, além de custos de reposição estimados entre **1,5x e 2,0x o salário anual** do colaborador (~R\$ 60 mil por posição em lideranças e tecnologia).

Objetivo da IA: Estimar com acurácia a probabilidade individual de desligamento voluntário ($P(\text{Turnover}=1 | X)$) em uma janela de 3 a 6 meses via Rede Neural MLP profunda, comparando-a contra uma regra heurística simples e modelos tradicionais de Machine Learning (Regressão Logística e Random Forest).

Demonstração Matemática Reconciliada do ROI (R\$ 1,2M/ano):

- Quadro Total:** 1.200 colaboradores | **Taxa Real de Turnover:** 21,0% a.a. = **252 desligamentos/ano**.
- Custo Anual Total do Turnover:** $252 \times \text{R\$ } 60.000 = \text{R\$ } 15.120.000,00/\text{ano}$.
- Cobertura do Modelo MLP (Recall = 79,4% com Threshold 0,35):** Identifica com antecedência **200 colaboradores em risco real** por ciclo.
- Conversão Preventiva do RH (Conservadora — 10%):** Retendo com sucesso 20 colaboradores dos 200 alertados:
 $20 \text{ colaboradores retidos} \times \text{R\$ } 60.000 = \text{R\$ } 1.200.000,00/\text{ano}$ (R\$ 1,2M em custos evitados).
- Custos de Sustentação Recorrente (Opex):** R\$ 60.000,00/ano (R\$ 5.000,00/mês para infraestrutura em nuvem, governança e retreinamento).
- Payback Reconciliado:** Capex (R\$ 175.000,00) / Economia Líquida Mensal (R\$ 95.000,00/mês) = **1,84 meses** (rigorosamente dentro da faixa de 1,8 a 2 meses).

2 Base de Dados e Calibração de Classes

- Fontes de Dados:** Base de 1.200 colaboradores simulando os atributos do SIRH, ponto eletrônico e avaliações 9-Box da Rede Ápice (anonimizada em conformidade com a LGPD).
- Calibração Rigorosa de Rótulo (21,0% Exato):** Para garantir a validade estatística das métricas, o limiar de rotatividade é fixado pelo **percentil 79 da probabilidade latente**, produzindo **exatamente 252 casos positivos (21,0%)**.
- Interações Não Lineares Reais de RH:** Inclusão de termos de interação multiplicativa ($\text{Horas_Extras} \times \text{Baixa_Satisfacao}$ e $\text{Alto_Desempenho_9Box} \times \text{Tempo_Sem_Promocao}$), refletindo cenários empíricos de burnout e fuga de talentos de alta empregabilidade.

3 Necessidade Real de IA vs. Regra Determinística Heurística

Implementou-se a regra manual de negócio: "Alertar quem possui ≥ 3 anos sem promoção E realiza horas extras frequentes".

Resultado Empírico no Conjunto de Teste:

- Recall da Regra: 35,4%** (deixa passar quase 65% dos colaboradores que de fato pedem demissão);
- Precisão da Regra: 31,2%** (quase 70% dos alertas são falsos alarmes, sobrecarregando o RH);
- Conclusão Técnica:** A regra determinística simples falha categoricamente por ignorar interações não lineares entre clima, remuneração e desempenho, justificando plenamente o uso de aprendizado de máquina.

4 Calibração e Justificativa Técnica do Limiar de Decisão (Threshold Tuning)

No People Analytics, o custo de um Falso Negativo (~R\$ 60 mil) é muito superior ao de um Falso Positivo (~R\$ 500). Avaliamos a curva de Precision-Recall para fundamentar a escolha matemática do limiar de corte ótimo no RH:

Threshold	Recall (Sensibilidade)	Precisão	F1-Score	Acurácia	Justificativa de Negócio
0,20	88,9%	49,1%	63,3%	78,0%	Alta sensibilidade, mas com excesso de falsos alarmes no RH.
0,25	84,1%	55,8%	67,1%	82,3%	Bom equilíbrio, priorizando retenção preventiva.
0,30	81,0%	60,7%	69,4%	85,3%	Equilíbrio robusto de precisão e cobertura.
0,35 (Ótimo)	79,4%	65,8%	71,9%	87,0%	Ponto ótimo: maximiza o F1-Score (71,9%) garantindo ~80% de Recall e alta precisão.
0,50	65,1%	75,9%	70,1%	88,0%	Critério conservador: deixa escapar 35% dos colaboradores em risco.

5 Modelagem Comparativa: ML Tradicional vs. Redes Neurais (MLP)

Todos os modelos foram treinados sob o mesmo split estratificado (75% Treino / 25% Teste) com padronização Z-score calculada exclusivamente no conjunto de treino:

Modelo Avaliado	Família Metodológica	Acurácia	Precisão	Recall (Sensibilidade)	F1-Score	ROC-AUC
Regra Determinística	Automação Heurística	72,0%	31,2%	35,4%	33,2%	-
Regressão Logística	ML Tradicional Linear	87,7%	66,2%	81,0%	72,9%	0,941
Random Forest	ML Tradicional Ensemble	87,3%	67,2%	71,4%	69,2%	0,912
Rede Neural MLP (Otimizada)	Deep Learning Tabular	87,0%	65,8%	79,4%	71,9%	0,928

6 Validação Multi-Seed (Robustez e Estabilidade em 3 Seeds)

Para atestar que os resultados não dependem de sorte no particionamento aleatório, avaliamos os modelos em 3 seeds distintas (42, 123 e 999):

Métrica / Modelo	Seed 42	Seed 123	Seed 999	Média ± Desvio Padrão
MLP — Recall (th=0.35)	79,4%	81,0%	82,5%	81,0% ± 1,5%
MLP — ROC-AUC	0,928	0,918	0,925	0,924 ± 0,005
Regressão Logística — Recall	81,0%	79,4%	82,5%	81,0% ± 1,5%
Random Forest — ROC-AUC	0,912	0,908	0,915	0,912 ± 0,003

7 MLOps: Monitoramento de Data Drift com Diagnóstico Condicional (PSI)

Implementou-se a função de cálculo do Population Stability Index (PSI) e uma rotina de diagnóstico condicional dinâmico avaliada em dois cenários empíricos:

- **Cenário 1 (Safr**

8 Limitações do Projeto, Riscos e Diretrizes Éticas (LGPD)

- **Limitação dos Dados Sintéticos:** Embora calibrada para espelhar a estrutura da Rede Ápice, dados de produção reais apresentam ruídos de registro de ponto e dados omissos em pesquisas de clima.
- **Trade-off entre Modelos:** A Regressão Logística provou ser um modelo altamente competitivo e interpretável. A MLP foi selecionada pela capacidade superior de mapear interações cruzadas de 2ª ordem, ao custo de maior opacidade sináptica.
- **Dependência da Atuação Humana:** O ROI de R\$ 1,2M depende criticamente de os Business Partners executarem planos de retenção eficazes.
- **Princípio Human-in-the-Loop & LGPD:** O sistema possui caráter **estritamente consultivo e preventivo**. É expressamente proibido pela governança utilizar o score para demissões profiláticas, advertências ou decisões desfavoráveis ao colaborador.