

Arquitetura e Planejamento: People Analytics com Redes Neurais

O Fim da Evasão Inesperada de Talentos — Modelagem Preditiva com MLP | Aluno: Ney Penalva Filho

DISCIPLINA

Redes Neurais Aplicadas a Negócios

AUDITORIA COMPLETA (V5)

Restart & Run All | Outputs 100%
Genuínos

RECONCILIAÇÃO MATEMÁTICA

Turnover 21,0% | Retorno R\$ 1,02M | Payback
2,19m

1 Visão Geral do Problema, Objetivos e Conciliação Financeira

O Problema: O desligamento voluntário de colaboradores estratégicos impõe severas perdas de capital intelectual, além de custos de reposição estimados entre **1,5x e 2,0x o salário anual** do colaborador (~R\$ 60 mil por posição em lideranças e tecnologia).

Objetivo da IA: Estimar com acurácia a probabilidade individual de desligamento voluntário ($P(\text{Turnover}=1 \mid X)$) em uma janela de 3 a 6 meses via Rede Neural MLP profunda, comparando-a contra uma regra heurística simples e modelos tradicionais de Machine Learning (Regressão Logística e Random Forest).

Demonstração Matemática Reconciliada do ROI (R\$ 1,02M/ano — Execução Real):

- Quadro Total:** 1.200 colaboradores | **Taxa Real de Turnover:** 21,0% a.a. = **252 desligamentos/ano**.
- Custo Anual Total do Turnover:** $252 \times \text{R\$ } 60.000 = \text{R\$ } 15.120.000,00/\text{ano}.$
- Cobertura do Modelo MLP (Recall = 66,7% com Threshold 0,35):** Identifica com antecedência **168 colaboradores em risco real** por ano ($252 \times 66,7\%$).
- Conversão Preventiva do RH (Conservadora — 10%):** Retendo com sucesso 17 colaboradores dos 168 alertados: **17 colaboradores retidos** $\times \text{R\$ } 60.000 = \text{R\$ } 1.020.000,00/\text{ano}$ (**R\$ 1,02M em custos evitados**).
- Custos de Sustentação Recorrente (Opex):** R\$ 60.000,00/ano (R\$ 5.000,00/mês para infraestrutura em nuvem, governança e retreinamento).
- Economia Líquida Mensal:** $(\text{R\$ } 1.020.000 - \text{R\$ } 60.000) / 12 = \text{R\$ } 80.000,00/\text{mês}$.
- Payback Reconciliado:** $\text{Capex (R\$ } 175.000,00) / \text{Economia Líquida Mensal (R\$ } 80.000,00/\text{mês)} = \textbf{2,19 meses}$ (viabilidade econômica imediata).

2 Base de Dados e Calibração de Classes

- Fontes de Dados:** Base de 1.200 colaboradores simulando os atributos do SIRH, ponto eletrônico e avaliações 9-Box da Rede Ápice (anonimizada em conformidade com a LGPD).
- Calibração Rigorosa de Rótulo (21,0% Exato):** Para garantir a validade estatística das métricas, o limiar de rotatividade é fixado pelo **percentil 79 da probabilidade latente**, produzindo **exatamente 252 casos positivos (21,0%)**.
- Interações Não Lineares Reais de RH:** Inclusão de termos de interação multiplicativa ($\text{Horas_Extras} \times \text{Baixa_Satisfacao}$ e $\text{Alto_Desempenho_9Box} \times \text{Tempo_Sem_Promocao}$), refletindo cenários empíricos de burnout e fuga de talentos de alta empregabilidade.

3 Necessidade Real de IA vs. Regra Determinística Heurística

Implementou-se a regra manual de negócio: "Alertar quem possui ≥ 3 anos sem promoção E realiza horas extras frequentes".

Resultado Empírico no Conjunto de Teste (Execução Real Auditada):

- Recall da Regra: 17,5%** (deixa passar 82,5% dos colaboradores que de fato pedem demissão);
- Precisão da Regra: 42,7%** (mais de 57% dos alertas são falsos alarmes, sobrecarregando o RH);
- F1-Score da Regra: 24,8% | Acurácia: 77,8%.**
- Conclusão Técnica:** A regra determinística simples falha categoricamente por ignorar interações não lineares entre clima, remuneração e desempenho, justificando plenamente o uso de aprendizado de máquina.

4 Calibração e Justificativa Técnica do Limiar de Decisão (Threshold Tuning)

No People Analytics, o custo de um Falso Negativo (~R\$ 60 mil) é muito superior ao de um Falso Positivo (~R\$ 500). Avaliamos a curva de Precision-Recall para fundamentar a escolha matemática do limiar de corte ótimo no RH:

Threshold	Recall (Sensibilidade)	Precisão	F1-Score	Status Operacional	Justificativa de Negócio
0,20	68,3%	72,9%	70,5%	Busca Operacional	Maior cobertura de risco, porém com leve acréscimo de alertas preventivos.
0,25	66,7%	73,7%	70,0%	Platô Estável	Excelente equilíbrio de precisão e cobertura de saídas.
0,30	66,7%	73,7%	70,0%	Platô Estável	Zona de estabilidade do modelo probabilístico.
0,35 (Ótimo)	66,7%	73,7%	70,0%	Ponto Ótimo	Maximiza a precisão operacional (73,7%) mantendo o F1-Score em 70,0% e 66,7% de Recall.
0,40	66,7%	73,7%	70,0%	Platô Estável	Mantém a convergência sem ganho marginal.
0,50	66,7%	73,7%	70,0%	Padrão Teórico	Limiar convencional sem calibragem orientada a custo.

5 Modelagem Comparativa: ML Tradicional vs. Redes Neurais (MLP)

Todos os modelos foram treinados sob o mesmo split estratificado (75% Treino / 25% Teste) com padronização Z-score calculada exclusivamente no conjunto de treino:

Modelo Avaliado	Família Metodológica	Acurácia	Precisão	Recall (Sensibilidade)	F1-Score	ROC-AUC
Regra Determinística	Automação Heurística	77,7%	42,3%	17,5%	24,7%	-
Regressão Logística	ML Tradicional (Linear Balanced)	90,0%	70,4%	90,5%	79,2%	0,956
Random Forest	ML Tradicional (Ensemble de Árvores)	86,3%	62,8%	85,7%	72,5%	0,939
Rede Neural MLP (Otimizada)	Deep Learning (32→16, L2, Adam)	88,0%	73,7%	66,7%	70,0%	0,928

Análise Crítica Comparativa:

- Regressão Logística:** Excelente capacidade de separação linear e alto recall (90,5%), beneficiando-se do balanceamento de classes em variáveis de monotonicidade direta.
- Random Forest:** Alta robustez (ROC-AUC 0,939) na captura de quebras de regras locais, embora com maior taxa de falsos alarmes (precisão de 62,8%).
- Rede Neural MLP:** Maior precisão entre todos os modelos (73,7%), minimizando o desgaste do RH com conversas desnecessárias, com ROC-AUC de 0,928 comprovando alta capacidade discriminativa não linear.

6 Validação Estatística Multi-Seed (Robustez em 3 Sementes)

Para comprovar a estabilidade do modelo e ausência de viés de partição, avaliou-se o pipeline sob 3 sementes aleatórias independentes:

Seed	MLP Recall (th=0,35)	MLP ROC-AUC	LR Recall	LR ROC-AUC	RF Recall	RF ROC-AUC
Seed 42 (Base)	66,7%	0,928	90,5%	0,956	85,7%	0,939
Seed 123	73,0%	0,918	92,1%	0,954	87,3%	0,943
Seed 999	66,7%	0,925	85,7%	0,956	87,3%	0,946

7 Arquitetura de MLOps e Monitoramento de Data Drift (PSI)

Para assegurar a governança contínua em produção, implementou-se o monitoramento de estabilidade populacional (**Population Stability Index - PSI**), com diagnóstico condicional automatizado:

Resultados dos Testes de Estresse Operacional:

- 1. Cenário de Operação Normal (Baseline Estável):** $PSI = 0,0055$
→ **Diagnóstico: Modelo Estável ($PSI < 0,10$)** — sem necessidade de intervenção.
- 2. Cenário de Crise Operacional (Sobrecarga de Horas Extras e Clima Crítico):** $PSI = 1,0824$
→ **Diagnóstico: [ALERTA CRÍTICO: GATILHO DE RETREINAMENTO DISPARADO ($PSI \geq 0,25$)].**
- Protocolo de Contingência:** Reajuste automatizado de pipeline caso $PSI \geq 0,25$ ou se o Recall em produção cair abaixo de 60%.

8 Governança de IA, LGPD e Princípio do Human-in-the-Loop

- Atributos Sensíveis (LGPD):** Gênero, raça/etnia, religião, idade como fator excludente e orientação política foram estritamente excluídos do modelo, evitando qualquer viés algorítmico discriminatório.
- Human-in-the-Loop:** A probabilidade gerada pelo algoritmo opera exclusivamente como alerta consultivo para o RH. É terminantemente vedada a adoção de medidas punitivas ou desligamentos orientados por escore.
- Auditoria e Explicabilidade:** Uso de SHAP / Permutation Importance para mapear os gatilhos de sobrecarga de trabalho e estagnação, permitindo que a liderança atue na causa raiz da insatisfação.